Reviving the Traditional Russian Orthography for the 21st Century

Sergei Winitzki

Text By The Bay 2015

April 24, 2015

Old Russian Orthography: what and why

- The Russian orthography was reformed in 1918
 - ▶ 4 letters Ѣь, Өө, li, Vv were physically removed from printing presses
 - ★ Often, Ъъ was also removed by mistake
- Classic Russian literature used the old orthography:
 - Pushkin, Turgenev, Dostoyevsky, Tolstoy, Chekhov, Nabokov, ...
- Replace $b \rightarrow e$, $\theta \rightarrow \phi$, $i \rightarrow u$, $v \rightarrow u$
 - motivation: "simplify the spelling"

Old Russian orthography: example

Nabokov, Storm (1930)

ГРОЗА

На углу, подъ шатромъ цвътущей липы, обдало меня буйнымъ благоуханіемъ. Туманныя громады поднимались по ночному небу, и когда поглощенъ былъ послъдній звъздный просвъть, слъпой вътеръ, закрывъ лицо рукавами, низко пронесся вдоль опустъвшей улицы. Въ тусклой темнотъ, надъ желъзнымъ ставнемъ парикмахерской, маятникомъ заходилъ висячій щить, золотое блюдо.

Вернувшись домой, я засталь вътерь уже въ комнатъ: — онъ хлопнуль оконной рамой и поспъшно от-

Natural language orthography changes naturally...

Hobbes, De cive (1651)

I. ALL Authors agree not concerning the definition of the Naturall Law, who notwithstanding doe very often make use of this terme in their Writings. The Method therefore, wherein we begin from definitions, and exclusion of all equivocation, is only proper to them who leave no place for contrary Disputes; for the rest, if any man say, that somewhat is done against the Law of Nature, one proves it hence, because it was done against the generall Agreement of all the most wise, and learned Nations: But this declares not who shall be the judg of the wisdome and learning of all Nations:

Some letters are now added: somwhat, judg Some letters are now removed: doe, generall, wisdome

...or when guided by a committee of experts

- A proposal for English, similar to the Russian spelling reform
 - Omit the mute "e" in endings, replace vowels to "simplify"
 - \star some o sum, made o maid, gate o gaitdd, breathe o breath
 - ▶ Replace the letters $c \rightarrow k/s$, $j \rightarrow g$, $x \rightarrow ks$, $y \rightarrow i$
 - \star place \to plais, played \to plaid, hence \to hens, john \to gon
 - ▶ Physically remove the letters C, J, X, Y from all computer keyboards
 - ★ because they are "a heritage of the horrible old times"

What happens if you ban a few letters...

- One generation later, nobody remembers anything was ever different
- You lose effective access to your own culture
 - ► Cannot print adequate critical editions of classic literature
 - Nobody wants to read even 100-year old books
 - Reprinting each old book is hard work for editors
- In Russia:
 - lacktriangle People born after pprox1950 are loath to read texts in the old orthography
 - Such texts are perceived to be irrevocably obsolete
 - ★ (regardless of what the texts say)

Main challenges in processing old Russian orthography

- As of 2000, no 8-bit encodings contained the letters $5\mathfrak{b}$, $9\mathfrak{e}$, Ii, Vv
 - Unicode support was not widespread
- No keyboard layouts, no screen fonts, few vector fonts
 - ► LATEX font support: nonstandard font encoding by AMS
- No spelling checker support, no OCR, no hyphenation

Back to 2015: State of the art

- The letters $5\mathfrak{b}$, $9\mathfrak{o}$, Ii, $9\mathfrak{o}$ are present in most Cyrillic fonts
 - typesetting, printing supported through Unicode
 - LATEX font support: OT2 font encoding only!
- Some spelling checker support (ispell, AbiWord, Open Office)
- Some language support for OCR
- No hyphenation support, no standard keyboard layouts

The oldrus-ispell project (1999-2003)

- http://oldrus-ispell.sourceforge.net/koi8-extended.html
- KOI8-C encoding (IETF draft), localization for the links browser
- A keyboard layout for X-Window and MS Windows 95
- Bitmapped X-Window fonts (BDF), the xcyr package
 - Became part of ucs-fonts and xfonts-cyrillic
- ispell dictionary for old Russian orthography
- A PostScript typesetter using BDF as Type 3 fonts (Perl)
- ullet A primitive converter, new ightharpoonup old orthography (Perl)

The KOI8-C encoding and screen fonts

Viewing Nabokov, Despair (1934) in Netscape using KO8-C

росту не знаю, съ чего начать. Смѣшонъ пожилой человѣкъ, который бѣгомъ, съ прыгающим томъ, догналъ [3] послѣдній автобусъ, но боится вскочить на ходу, и виновато улыбаясь, ещо ужто не смѣю вскочить? Онъ воетъ, онъ ускоряеть ходь, онъ сейчасъ уйдеть за уголъ, непоп это разсказа. Образъ довольно громоздкій. Я все еще бѣгу.

ь мой быль ревельскій нѣмець, по образованію агрономъ, покойная мать — чисто-русская. С въ жаркіе лѣтніе дни она, бывало, въ сиреневыть шелкахъ, томная, съ вѣеромъ въ рукћ, пол в, кушала шоколадъ, и наливались сѣнокоснымъ вѣтромъ лиловые паруса спущенныхъ што аго подданнаго, интернировали, — я только-что поступилъ въ петербургскій университеть, г тырнадцатаго, до середины девятнадцатая года я прочелъ тысяча восемнадцать книгъ, — вен нію я на три мѣсяца застрялъ въ Москвѣ и тамъ женился. Съ двадцатаго года проживалъ въ стаго года, уже переваливъ лично за тридцать пять — —

кацавейкъ. 📉		koi8c-table.gif (671x312) 0.0s 100% [1/1] h0/c0/g0														
лавныхъ мс		81	82	83	84	85	86	87	88	89	8A	8B	90	8D	- BE	8F
агъ. Дъло бъ	3	ŕ		ŕ	**		+	8	€		B	<	Н	K	ħ	Ų
90		91	92	93	94	95	96	97	98	99	9A	9B	9C	9B	9E	9F
лакомки. Не	7		*	"	**		-	-	£	1.0	ъ	>	њ	Ŕ	ħ	Ų
эжатъ, мнѣ х	5	A1	A2	A3	84	A5	A6	87	AS	A9	- AA	AB	AC	AD	Æ	AF
сно вести пл		٧	ь	ë	ε	S	i	ï	j	0	TH	«	0	٢	ğ	
ельзя. Спокс		B1	BZ	B3	B4	85	B6	B7	188	B9	BA	BB	BC	BD	BE	BF
овара изобр о		٧	ъ	Ë	£	S	I	Ĩ	J	NF	C	>	θ	Г	9	0
и на наше пр	>	C1	C2	C3	C4	C5	06	C7	C8	C9	CA	CB	CC	CB	CE .	CF
таксомотор к	3	а	б	ц	Д	е	ф	г	×	и	Й	к	п	м	н	0
го но въде)	D1	02	D3	D4	105	D6	D7	108	D9	DA	DB	DC	DD	D€	DF
не засталък Г		Я	P	С	т	y	ж	В	ь	bi	3	W	3	щ	ч	ъ
мъ сообщити	0.77	E1	E2	E3	E4	E5	E6	E7	E8	E9	EA	EB	EC	ED	EE	EF
ь горой, похо	I	A	Б	Ц	Д	E	Ф	Г	X	И	Й	K	U	M	Н	0
		F1	F2	F3	F4	F5	F6.	F7	F8	F9	FA	FB	FC	FD	FE	FF
а, то рисуя н		Я	P	C	T	y	X	В	Ь	Ы	3	Ш	3	Щ	4	Ъ

Working with the oldrus-ispell dictionary

Proofreading Melgunov's "Red Terror in Russia" (1924)

File Edit Search Preferences Shell Macro Windows

Shell Command in Progress -- Press Ctrl+. to Cancel

"Еженедъльникъ Ч. К." *(6) никогда ничего больше {39} не было опубликовано. А между тъм мы знаем, что людей в эти дни в Москвъ по общим свъдъніям было разстрълено больше 300 *(7).

Тъ, которые сидъли в эти поистинъ мучительные дни в Бутырской тюрьмъ, когда были арестованы тысячи людей из самых разнообразных общественных слоев, никогда не забудут своих душевных переживаній.

было время 🗐 ispell террора". без File: spellTmp присутство Невольно вновь вспоминаешь слова В. Г. Короленко, мимолетно б автомобили , которая может ее молчаливо терпъть 5 протеста. И пожалъешь, как Г каждом авт "с вещами" 0: бей 1: безе связывать 2: безо

"В пам Sergei Winitzki (Versal Group Inc.)

3: безъ

сидъл в эт

кошмары. В

Main linguistic challenges

To convert texts to the old Russian orthography, we...

- disambiguate word pairs that became homographs...
 - ▶ самого самаго, синее синѣе, оселъ осѣлъ
- ...and also some homophones that became homonyms
 - есть ѣсть, нежить нѣжить, миръ міръ, некогда нѣкогда
- restore old grammatical endings
 - lacktriangle они, туманные звезды ightarrow онlacktriangle , туманныя звlacktriangle зв
- restore old letters in word stems, prefixes, and suffixes
 - ▶ Оедоръ (Theodor), орөографія (orthography), муро (myrrhe)
 - lacktriangle рассвирепел ightarrow разсвирlacktriangleпълlacktriangle, нежнейшего ightarrow нlacktriangleжнlacktriangleй

Main linguistic challenges

Disambiguation requires:

- identifying part of speech
- identifying inflection (number, gender, case)
- for some words, even identifying semantic content
 - ▶ prononciation details (stress, e/ë) do not always suffice

Main challenges